
















Jacobs Alexandre, Bonaert Gregory, Ruggoo Prateeba, Rouma Florian, Engelman David, Engelman Benjamin


MODÈLE (RIDGE CLASSIFIER)

Ce type de modèle est une amélioration de la régression linéaire. En plus de minimiser les écarts entre les valeurs prédites et réelles, il force les coefficients β à être plus petits et donc minimise l'impact du bruit dans les problèmes avec un grand nombre de features.




DATASET

Un dataset composé de 60.000 articles de presse, sur des sujets divers, labellisés faux ou vrai. 80 % du dataset a été utilisé pour l'entraînement du modèle et les 20 % restants pour le tester.



Termes les plus associés aux Fake news et aux Real News



Meilleures combinaisons de modèles et features

	Modèle	Features	Précision
1	Ridge Classifier	Tf-Idf Ponctuation Pronoms	0.9737
2	Ridge Classifier	Tf-ldf Ponctuation Pronoms Sentimens	0.9730
3	Ridge Classifier	Tf-ldf Ponctuation Sentiments	0.972
4	Ridge Classifier	Tf-ldf Ponctuation	0.971
5	Ridge Classifier	Tf-ldf Sentiments	0.9704
6	Ridge Classifier	Tf-ldf	0.9702
6	Passive-Aggressive	Tf-ldf Sentiments Pronoms	0.9702
8	Passive-Aggressive	Tf-Idf Pronoms	0.96
9	Logistic regression	Tf-ldf Text_Count	0.95
10	Logistic regression	Tfidf Text_Count Sentiment	0.94

